

Informe técnico — Customer Support Tickets

Proyecto final y defensa del caso de estudio

Fuente principal: notebook_customer_support_tickets.ipynb y customer_support_tickets_depurado.csv. Los resultados numéricos de esta sección se obtuvieron al ejecutar el notebook entregado.

1. Problema organizacional y público objetivo

El caso busca apoyar al área de soporte al cliente en dos tareas: (1) evaluar si es posible predecir la prioridad de un ticket antes de su atención usando variables estructuradas; y (2) segmentar tickets en perfiles operativos para facilitar análisis y acciones diferenciadas. La pregunta de negocio, derivada del objetivo del notebook, es: **¿Cómo puede el área de soporte utilizar los datos de tickets para mejorar la priorización y comprender perfiles operativos de atención?**

2. Datos y proceso ETL

El dataset contiene 8,469 registros y 17 columnas. Incluye información del cliente, producto, tipo y canal del ticket, estado, prioridad, marcas de tiempo y satisfacción. El ETL del notebook elimina duplicados, convierte 'Date of Purchase' a fecha, convierte 'Customer Satisfaction Rating' a numérico y crea 'Purchase Year' y 'Purchase Month'. No se detectaron duplicados; después del ETL permanecieron 8,469 filas. Hay variables con valores faltantes, especialmente Resolution, Time to Resolution y Customer Satisfaction Rating.

3. EDA y hallazgos relevantes

La prioridad tiene cuatro clases con volúmenes cercanos: Critical 2,129; High 2,085; Medium 2,192; Low 2,063. Los canales también están distribuidos de forma similar: Email 2,143; Phone 2,132; Social media 2,121; Chat 2,073. El rating de satisfacción está disponible para 2,769 tickets y su promedio es 2.99. Esta estructura relativamente equilibrada justifica reportar F1 macro además de accuracy.

4. Modelos de machine learning y comparación con línea base

Modelo	Accuracy	F1 macro
Línea base (clase frecuente)	0.2586	0.1027
Árbol de decisión	0.2550	0.1875

El árbol obtiene un F1 macro superior al benchmark (+0.0848), pero su accuracy es ligeramente inferior (-0.0035). Su recall para Critical es 0.4812, mientras que para High y Low es 0.02 y 0.03, respectivamente. El propio notebook concluye que, con estas variables, no hay evidencia suficiente para automatizar la clasificación. La segmentación K-Means evaluó k=2 a 6 y seleccionó k=6 por mayor silhouette (0.3135). PCA explicó 26.3% y 25.0% de la varianza en sus dos componentes.

5. Recomendaciones y limitaciones

Usar el modelo actual como herramienta exploratoria, no como clasificador automático. Para una siguiente iteración: incorporar texto del ticket mediante NLP, validar con cross-validation, evaluar costos diferenciados de errores y probar datos de producción. Para los segmentos, validar si los perfiles son accionables antes de convertirlos en reglas operativas. La segmentación es descriptiva y no demuestra causalidad.

6. Reflexión ética

El dataset contiene datos personales y de contacto, por lo que el análisis debe aplicar minimización de datos, control de acceso y protección de información identificable. Las predicciones de prioridad pueden afectar el orden de atención; por ello deben existir supervisión humana, trazabilidad y revisión de errores, especialmente en prioridades críticas. Los segmentos no deben interpretarse como atributos personales o causas de comportamiento sin evidencia adicional.

7. Declaración de uso de herramientas de IA

Se utilizaron herramientas de IA como apoyo para estructurar, revisar y preparar los entregables, además de automatizar tareas de documentación y presentación. Los datos, código base, variables, métricas y conclusiones técnicas se conservaron conforme al notebook y dataset proporcionados. El equipo debe revisar y validar el contenido final antes de su entrega y declarar cualquier uso adicional de IA que haya ocurrido durante el desarrollo.