



Caso de estudio Customer Support Tickets

Santo Israel Herrera Payano

AI and Organizational Data Management (CIA6041)

Doctor: Jhony Andrés Guzmán Henao

Fecha: 3/10/2026

1. Problema organizacional y público objetivo

El caso busca apoyar al área de soporte al cliente en dos tareas: (1) evaluar si es posible predecir la prioridad de un ticket antes de su atención usando variables estructuradas; y (2) segmentar tickets en perfiles operativos para facilitar análisis y acciones diferenciadas.

Pregunta de negocio: ¿Cómo puede el área de soporte utilizar los datos de tickets para mejorar la priorización y comprender perfiles operativos de atención?

La solución está dirigida principalmente a responsables de soporte y operaciones que necesitan comprender la demanda, la distribución de prioridades y las características de los casos atendidos.

2. Datos y proceso ETL

El dataset contiene 8,469 registros y 17 columnas. Incluye información del cliente, producto, tipo y canal del ticket, estado, prioridad, marcas de tiempo y satisfacción.

Etapa		Tratamiento
Etapa	Extrac	Carga del CSV y revisión de estructura, dimensiones y primeras observaciones.
	Transf	Eliminación de duplicados; conversión de Date of Purchase a fecha; conversión de Customer Satisfaction Rating a numérico; creación de Purchase Year y Purchase Month.
	Qualit	Verificación de duplicados y valores faltantes, especialmente en Resolution, Time to Resolution y Customer Satisfaction Rating.
	Análisis	Dataset limpio utilizado para EDA, clasificación y segmentación.

Resultado del ETL: 0 duplicados eliminados y se conservaron los 8,469 registros. Los valores faltantes se concentran especialmente en variables que dependen de que un ticket haya sido resuelto o calificado.

3. Análisis exploratorio de datos (EDA)

El EDA permitió revisar la distribución de la variable objetivo y de variables operativas relevantes antes del modelado.

Distribución de prioridad

Prioridad	Tickets	%
Critical	2,129	25.1%
High	2,085	24.6%
Medium	2,192	25.9%
Low	2,063	24.3%

Las cuatro clases presentan volúmenes relativamente cercanos. No existe una clase dominante de forma extrema, por lo que además de accuracy se utiliza F1 macro para evaluar el desempeño de clasificación.

Distribución por canal

Canal	Tickets
Email	2,143
Phone	2,132
Social media	2,121
Chat	2,073

Los canales también presentan una distribución similar. La satisfacción está disponible para 2,769 tickets y su promedio es 2.99/5. Los faltantes de satisfacción, resolución y tiempo de resolución deben interpretarse en relación con el estado del ticket.

Hallazgos del EDA

- La variable objetivo está relativamente equilibrada entre sus cuatro categorías.
- La demanda está repartida entre los cuatro canales sin concentración extrema.
- La satisfacción promedio disponible es 2.99/5, pero no representa a todos los tickets.
- Los valores faltantes son relevantes para interpretar resolución y satisfacción.

4. Machine Learning y comparación con la línea base

El objetivo supervisado es predecir Ticket Priority usando variables estructuradas. Primero se estableció una línea base con DummyClassifier (clase más frecuente) y luego un árbol de decisión.

Modelo	Accuracy	F1 macro
Línea base	0.2586	0.1027
Árbol de decisión	0.2550	0.1875

El árbol mejora el F1 macro de 0.1027 a 0.1875 (+0.0848), pero su accuracy es ligeramente inferior: 0.2550 frente a 0.2586 (-0.0035).

Métricas adicionales del árbol

Métrica	Resultado
Precision macro	0.2502
Recall macro	0.2505
F1 macro	0.1875
Recall — Critical	0.4812

El recall de Critical es 0.4812, por lo que el modelo recupera aproximadamente el 48% de los casos Critical del conjunto de prueba. El notebook concluye que, con estas variables, no hay evidencia suficiente para automatizar la clasificación.

5. Segmentación con K-Means

Se evaluaron valores de k entre 2 y 6 mediante silhouette score. Los resultados fueron: k=2: 0.2414; k=3: 0.2606; k=4: 0.2687; k=5: 0.2931; k=6: 0.3135. Por ello se seleccionó k=6.

La segmentación es descriptiva: seis grupos según este criterio no demuestra por sí sola que todos sean accionables para el negocio.

6. Hallazgos, recomendaciones y limitaciones

Hallazgos integrados

- La distribución de prioridades es relativamente equilibrada.
- El árbol aporta una mejora de F1 macro frente a la línea base, pero no mejora accuracy.
- La identificación de Critical alcanza recall 0.4812 y debe interpretarse con cautela.
- K-Means selecciona seis clusters por el mayor silhouette observado (0.3135), que requieren validación operativa.

Recomendaciones

1. Mantener el modelo actual como herramienta exploratoria y no como clasificador automático.
2. Incorporar el texto del ticket mediante NLP en una siguiente iteración, ya que el modelo actual no aprovecha la información semántica.
3. Utilizar validación cruzada y evaluar costos diferenciados de errores.
4. Probar el enfoque con datos de producción antes de cualquier despliegue.
5. Validar con responsables de soporte si los segmentos son accionables antes de convertirlos en reglas operativas.

Limitaciones

El análisis depende de las variables disponibles; satisfacción y resolución presentan valores faltantes. El modelo supervisado no incorpora el texto de los tickets. Además, la segmentación es descriptiva y no establece causalidad.

7. Reflexión ética

El dataset contiene datos personales y de contacto, por lo que deben aplicarse minimización de datos, control de acceso y protección de información identificable. Las predicciones de prioridad pueden afectar el orden de atención; por ello cualquier uso futuro debe mantener supervisión humana, trazabilidad y revisión de errores, especialmente en prioridades críticas. Los segmentos no deben interpretarse como atributos personales o causas de comportamiento sin evidencia adicional.

8. Declaración de uso de herramientas de IA

Se utilizaron herramientas de inteligencia artificial como apoyo para estructurar, revisar y preparar los entregables, además de automatizar tareas de documentación y presentación. Los datos, código base, variables, métricas y conclusiones técnicas se conservaron conforme al notebook y dataset proporcionados. El contenido final debe ser revisado y validado por el integrante antes de la entrega, y cualquier uso adicional de IA realizado durante el desarrollo debe declararse de forma transparente.

9. Conclusión

El proyecto permitió recorrer un flujo completo de analítica: preparación de datos, EDA, clasificación supervisada, segmentación y visualización. El árbol de decisión mejora el F1 macro respecto de la línea base, pero no supera su accuracy; por ello, el resultado no respalda la automatización de la prioridad con las variables disponibles. K-Means selecciona seis clusters por el mayor silhouette observado (0.3135), pero estos perfiles deben validarse desde el punto de vista operativo.

El dashboard de Tableau complementa el análisis al convertir los resultados técnicos en información visual para explorar la distribución de tickets por prioridad, canal, estado y tipo. La recomendación general es utilizar el modelo y los segmentos como apoyo exploratorio, mientras se incorporan texto, validación cruzada y criterios de costo/impacto antes de cualquier automatización.